

TALLER CIENCIA DE DATOS



IDATHA



SAP next-gen»

CRONOGRAMA

Bloque 1

- Conceptos básicos

Coffee break (15 minutos)

Bloque 2

- Armado de grupos laboratorio
- Ejemplo práctico



(Taken from MIND : a Quarterly Review of Psychology and
Philosophy. Vol. LIX. , N.S., No. 236, October , 1950.)

COMPUTING MACHINERY AND INTELLIGENCE


by

A. M. TURING.


1. The Imitation Game.

I propose to consider the question, 'Can machines think?'. This should begin with definitions of the meaning of the terms 'machine' and 'think'. The definitions might be framed so as to reflect so far as possible the normal use of the words, but this attitude is dangerous. If the meaning of the words 'machine' and 'think' are to be found by examining how they are commonly used it is difficult to escape the conclusion that the meaning and the answer to the question, 'Can machines think?' is to be sought in a statistical survey such as a Gallup poll. But this is absurd. Instead of attempting such a definition I shall replace the question by another, which is closely related to it and is expressed in relatively unambiguous words.

The new form of the problem can be described in terms of a game which we call the 'imitation game'. It is played with three people, a man (A), a woman (B), and an interrogator (C) who may be of either sex. The interrogator stays in a room apart from the other two. The object of the game for the interrogator is to determine which of the other two is the man and which is the woman. He knows them by labels X and Y, and at the end of the game he says either 'X is A and Y is B' or 'X is B and Y is A'. The interrogator is allowed to put questions to A and B thus:





¿Ciencia de datos?
¿Científicos de datos?
¿Big data?



Ciencia de Datos

La **ciencia de datos** es un campo **interdisciplinario** que involucra **métodos científicos**, procesos y sistemas para extraer conocimiento o un mejor entendimiento de datos.


"Cuarto paradigma" de la ciencia (empírico, teórico, computacional y ahora basado en datos) y afirmó que "todo lo relacionado con la ciencia está cambiando debido al impacto de la tecnología de la información y el diluvio de datos", Jim Gray

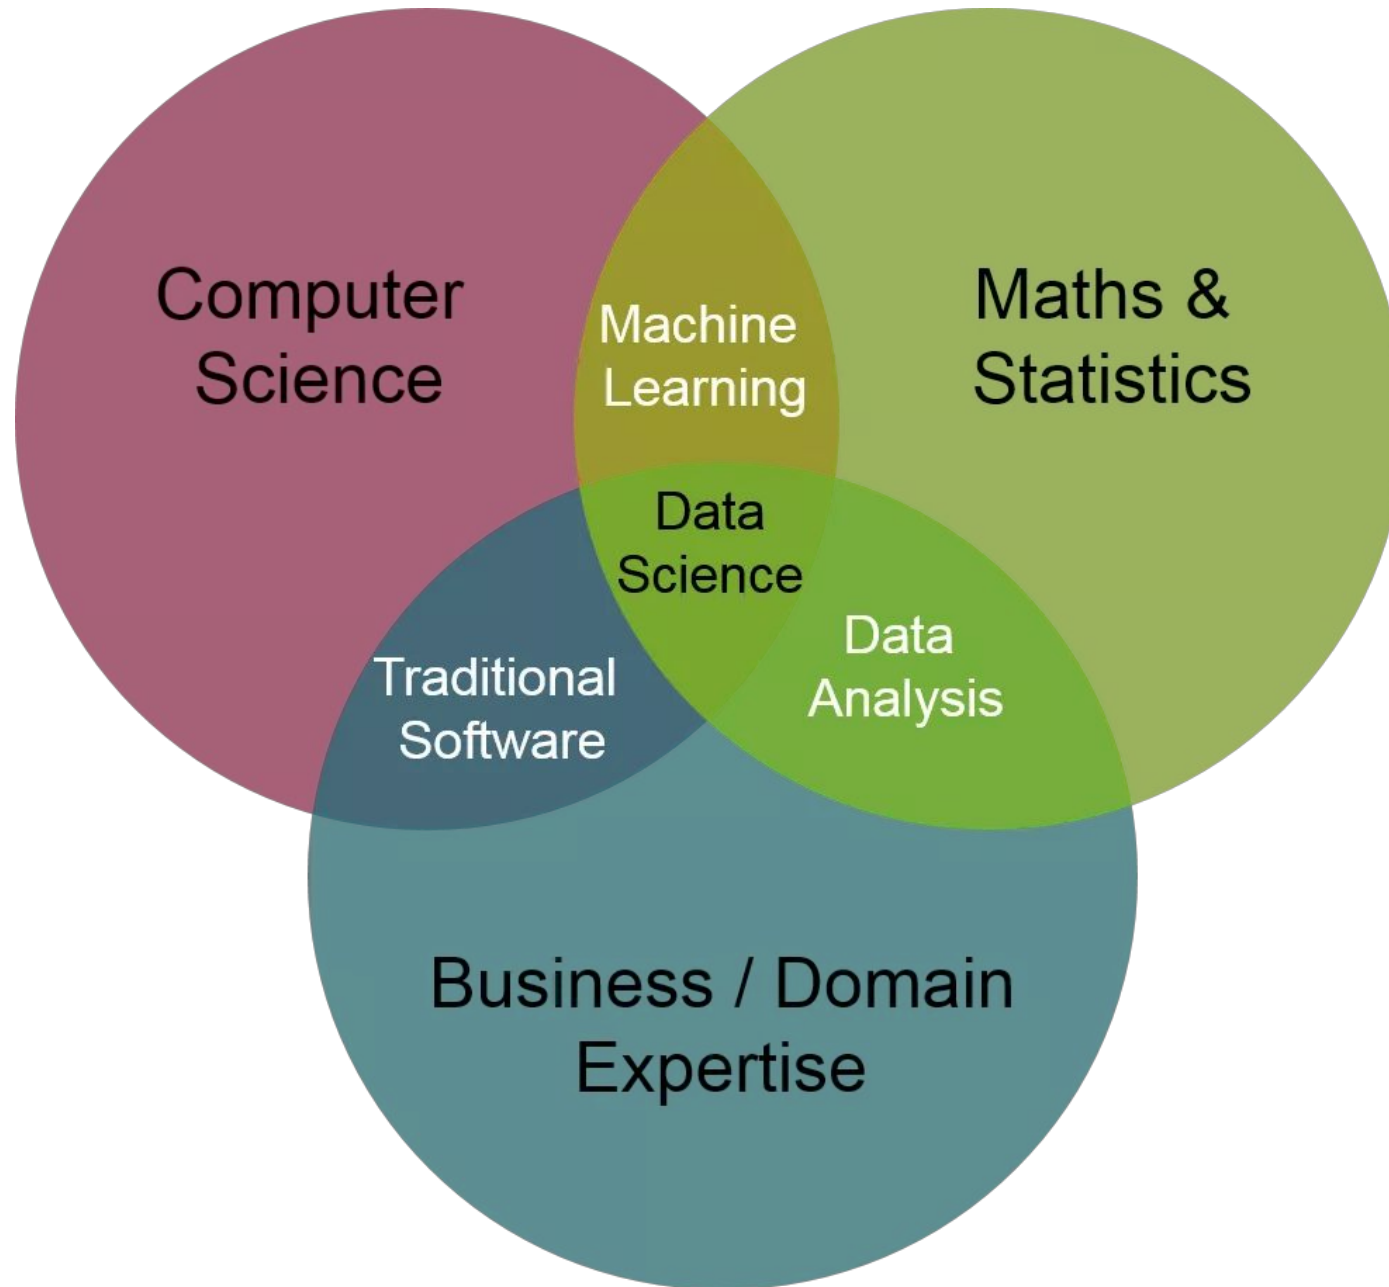


Paradigmas de la ciencia

- Hace mil años:
la ciencia era **empírica**
descripción de fenómenos naturales
- Últimos siglos:
rama **teórica**
utilización de modelos, generalizaciones
- Últimas décadas:
una rama **computacional**
simulación de fenómenos complejos
- Hoy: la **exploración de datos** (e-ciencia)
unificación de teoría, experimentación y simulación
- Los datos se capturan mediante instrumentos
o se generan mediante simulador
- Procesados mediante software
- La información/conocimientos se almacenan
en computadora
- El científico analiza la base de datos o los archivos
mediante administración de datos y estadística

$$\left(\frac{\dot{a}}{a}\right)^2 = \frac{4\pi G\rho}{3} - K\frac{c^2}{a^2}$$





2019 *This Is What Happens In An Internet Minute*



Mantenimiento Predictivo

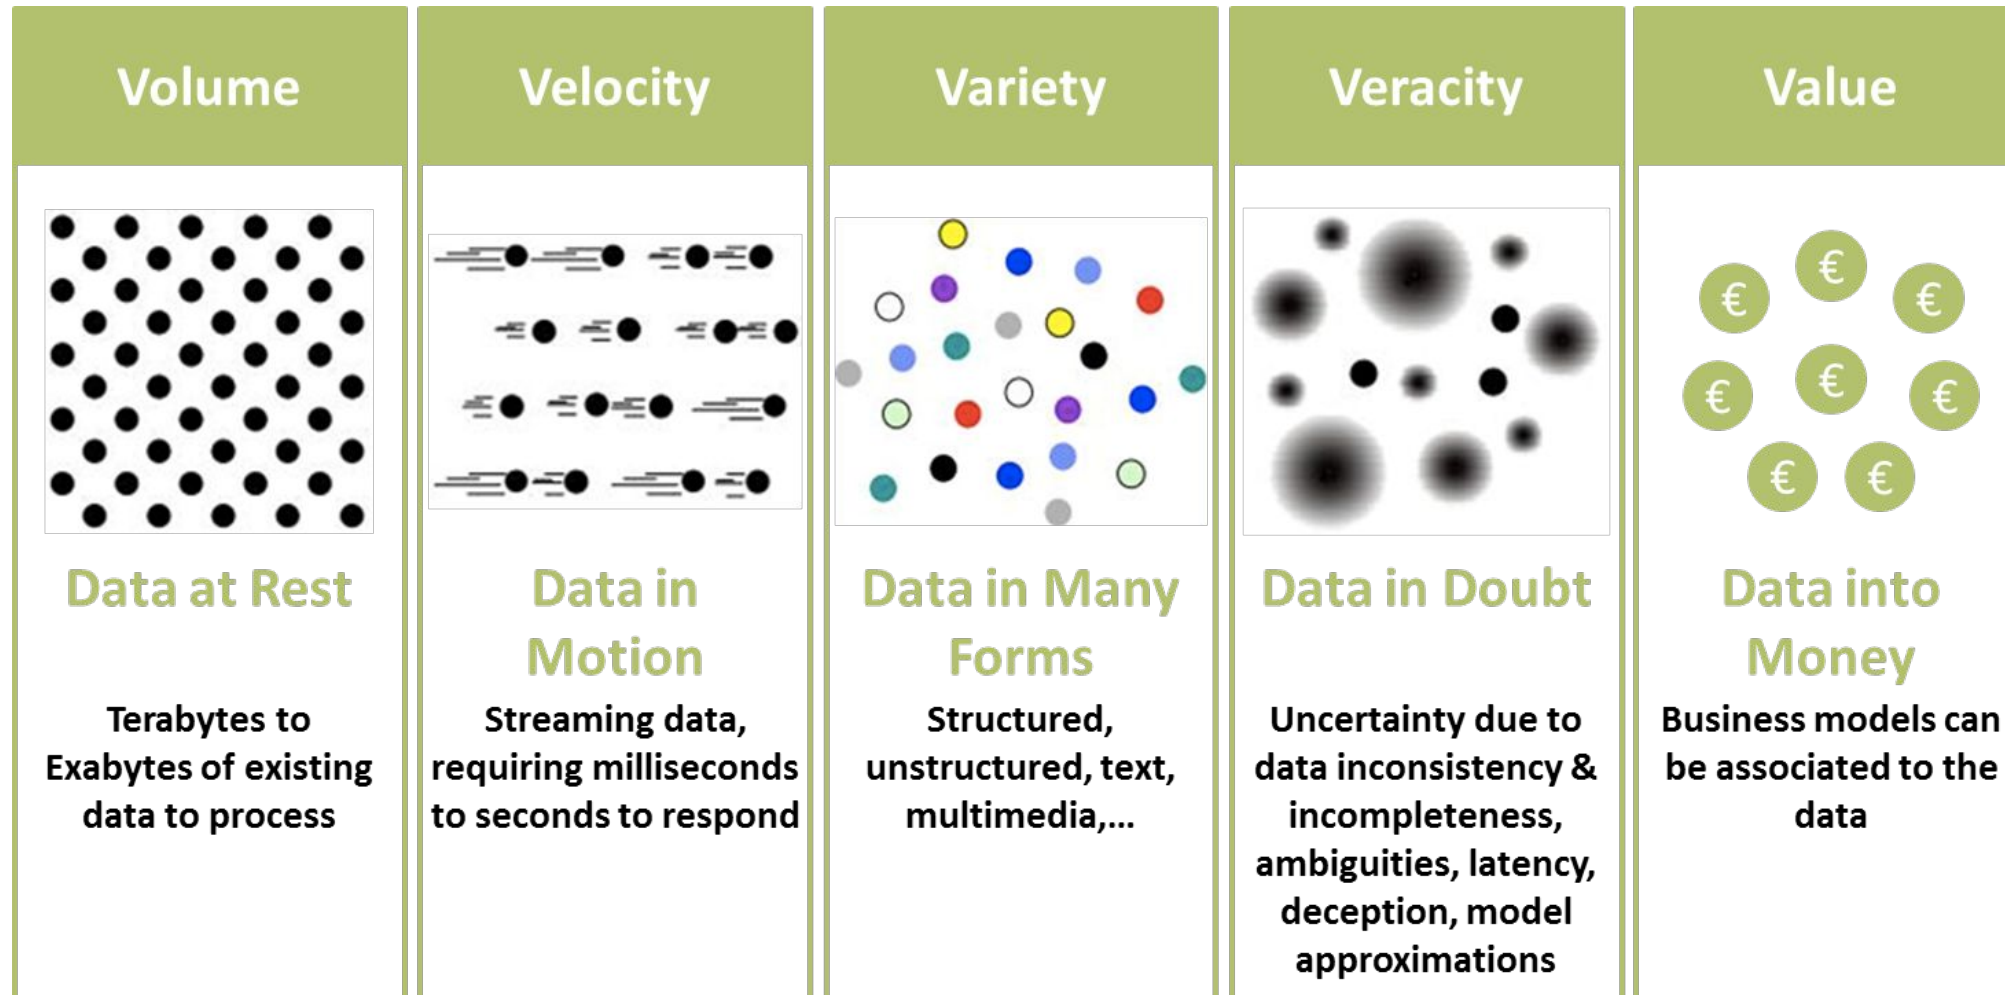
300 sensores

200 GB de datos por día

Se transmiten y analizan en
Dinamarca



BIG DATA




Workflow: CRISP-DM

CRISP-DM es la sigla para *CRoss Industry Standard Process for Data Mining*.


Es un modelo de proceso, propuesto inicialmente para proyectos de minería de datos y que puede ser adaptado para proyectos en ciencia de datos. El proceso es independiente del sector de la industria del cual proviene el problema que queremos resolver o de las tecnologías utilizadas.

Fue presentado por primera vez en el año 2000, a través del trabajo [CRISP-DM: Towards a standard process model for data mining](#)

CRISP-DM: Fases



CRISP-DM: Business Understanding




Comprensión de los objetivos y requisitos del proyecto desde una perspectiva empresarial, y luego convertir este conocimiento en una definición del problema de minería de datos, y un plan preliminar diseñado para alcanzar los objetivos.

Etapas:

- Determinar objetivos empresariales.
- Analizar la situación actual.
- Determinar objetivos de data science.
- Planificación con duración, recursos y riesgos.


CRISP-DM: Business Understanding (II)



Discutiendo con el cliente (negocio) determinar:

- Situación comercial o problema:
 - Estructura de la organización
 - Áreas involucradas/afectadas
 - Solución actual
- Objetivos comerciales específicos
 - Verificar si hay objetivos complementarios
- Criterios de rendimiento desde la perspectiva de negocio
 - Objetivos y subjetivos

CRISP-DM: Business Understanding (III)



También con el cliente relevar:

- Recursos
 - Infraestructura, datos y personal
- Requisitos, supuestos y restricciones
 - Restricciones legales o de seguridad
 - Supuestos de calidad de fuentes o despliegue de resultados
 - Acceso a datos y permisos
- Riesgos y contingencia
 - Tiempo, dinero, datos y resultados
- Costo/beneficio
 - Beneficio potencial esperado

Ejemplo: Supermercado Target



Un día, la cadena de supermercados Target decide invertir en el servicio de retención y fidelización de sus clientes, utilizando técnicas de data mining. Para ello, utilizaron datos de sus bases de datos de clientes, en las cuales almacenaban todas las compras realizadas por un cliente, junto con sus datos personales, información de crédito, etc. El objetivo era conocer mejor a sus clientes para realizar campañas de cupones de descuentos personalizados.

Luego de analizar los datos, uno de los analistas descubre ciertos patrones interesantes, como por ejemplo los productos que en la mayoría de los casos, compraban mujeres durante sus primeros meses de embarazo. Algunos hallazgos:

- Mujeres embarazadas compran grandes cantidades de lociones sin aroma, alrededor del segundo trimestre de embarazo.
- Algunas veces, en las primeras 20 semanas, las mujeres embarazadas consumen suplementos nutricionales como calcio, magnesio y zinc.

Descubrieron más de 25 productos que usualmente compran mujeres embarazadas en algún momento del embarazo y con ellos construyeron un puntaje de “predicción de embarazo”. De esta forma, comenzaron a enviar cupones de descuento en productos específicos como cremas, lociones, pañales, etc., a mujeres con un puntaje de “predicción de embarazo” alto.

Ejemplo: Supermercado Target (cont)



Tiempo después un hombre enojado llama a una tienda Target y pide para hablar con el gerente:

“Mi hija recibió este email de ustedes! Ella todavía está en secundaria, y ustedes le están enviando cupones para ropa de bebé y pañales? Están tratando de animarla a que se embaraze?”

Tiempo después la misma persona llamó para disculparse. Su hija efectivamente estaba embarazada.

Lo interesante de este ejemplo, además del hecho de que un supermercado supo que una adolescente estaba embarazada incluso antes que ella misma, es repasar la situación y preguntarse:


¿Como cliente de Target, como me sentiría si ellos saben cosas sobre mi que incluso ni yo se?

Quizás desde el cliente (Target), faltó definir una estrategia más sensible para enviar cupones a mujeres potencialmente embarazadas, quizás esperar hasta el tercer mes de embarazo, no ser tan explícito, etc.

Fuente:

<https://www.forbes.com/sites/kashmirhill/2012/02/16/how-target-figured-out-a-teen-girl-was-pregnant-before-her-father-did/#64e598c86668>

CRISP-DM: Data Understanding




Recolección inicial de datos y procesos con actividades con el objetivo de familiarizarse con los mismos, identificar problemas en la calidad de los datos, descubrir primeros insights en los datos, o detectar subconjuntos de datos para formular hipótesis sobre datos ocultos. Hay un vínculo muy cercano entre las etapas de *Comprensión del negocio* y *Comprensión de los datos*

Etapas:


- Recopilar datos disponibles
- Explorar y describir los datos con tablas y gráficos.
- Verificar calidad de los datos.

CRISP-DM: Data Understanding (II)



- Obtener datos para su exploración y análisis
- Debo contar con acceso a los mismos, o tener una copia local
- Es muy importante contar con meta-data o documentación sobre los datos
- Fuentes:
 - Datos existentes: transaccionales, encuestas, registros web, CRM
 - Datos adquiridos: solicitud a secciones o áreas “dueñas” de datos
 - Datos adicionales: necesidades aún no cubiertas (proyecto en sí mismo)


CRISP-DM: Data Understanding (III)



Checklist de descubrimiento

- Cantidad de datos (general)
- Atributos relevantes o “prometedores”
- Atributos no relevantes
- Tipos de valores: tipo de dato de cada variable
- Codificación: representación de características
- Densidad de datos en atributos (suficiencia)
- Data matching y data fusion
- Valores faltantes

CRISP-DM: Data Preparation




Actividades para construir el conjunto de datos de entrenamiento. Estas tareas son ejecutadas en múltiples oportunidades y sin orden. Las tareas incluyen selección y transformación de tablas, registros y atributos, y limpieza de datos para las herramientas de modelado.

Etapas:

- Selección de subconjunto de datos.
- Limpieza de datos.
- Creación de nuevos atributos (ingeniería de atributos).
- Transformaciones a atributos
- Fusión y agregado de conjuntos y registros.
- Verificación de formato de datos para el modelado.
- División en conjuntos de datos de prueba y entrenamiento.

CRISP-DM: Data Preparation (II)




Analizar los datos para determinar

- Datos relevantes a los objetivos (de negocio y de Data Science)
- Selección por filas
 - No todos los registros son relevantes (fecha, falta de información, errores)
 - Necesidad de estudiar un subconjunto específico
- Selección por columnas
 - Decisiones sobre el uso de atributos
 - Pueden existir restricciones
 - Necesidad de crear nuevos valores a partir de los actuales
- Qué datos debo limpiar
 - Recurrir al informe de calidad (si existe)

La preparación de datos insume entre el 50 y 70% del tiempo y esfuerzo del proyecto


CRISP-DM: Modeling



Se seleccionan y aplican varias técnicas de modelado y se calibran los parámetros para mejorar los resultados. Hay varias técnicas que tienen requerimientos específicos sobre la forma de los datos, por lo que puede ser necesario volver a la fase de preparación de datos.

(Mañana veremos más en profundidad esto)


CRISP-DM: Evaluation



Evaluación del modelo (o modelos) construidos, que parecen tener gran calidad desde una perspectiva del análisis de datos.

(Mañana veremos más en profundidad esto)

CRISP-DM: Despliegue



Esta fase depende de los requerimientos, pudiendo ser simple como la generación de un reporte o compleja como la implementación de un proceso de explotación de información que atraviese a toda la organización, disponibilizar un modelo predictivo como servicio, etc.



Practise Time



TALLER CIENCIA DE DATOS

Sebastián García

sgarcia@idatha.com

@dsgarcia

Emiliano Viotti

eviotti@idatha.com

@Efviodo

Manu Reynaert

mreynaert@idatha.com

Bitly <http://bit.ly/idatha-ds-course>

Long <https://github.com/efviodo/idatha-data-science-course>



Set-up Colab



1. Ir al link donde se encuentra el material del taller (repositorio Github)
2. Abrir el primer Notebook 01 - DS - Conceptos Basicos Jupyter Notebooks - Python.ipynb
3. Apretar en el botón "Open In Colab"
4. Crear una copia local del Notebook
5. Empezar a trabajar

Más info acerca de Colab en

<https://colab.research.google.com/notebooks/welcome.ipynb>